

Big Data Analysis

Λουκάς Νικολάου
22390158

Γεώργιος Κατεχάκης
22390087

Σέρτζιο Χότζα
22390301


Κωνσταντίνος Γιακουμής
21390035




Dataset

Το dataset στο οποίο κατασταλάξαμε είναι το **MovieLens** με **20M entries** με τα εξής αρχεία:

- **movie**
- **tag**
- **rating**
- **link**
- **genome_tags**
- **genome_scores**



Tables and Relations



userId	movieId	rating	timestamp
3	1	4	1999-12-11 13:36:47
6	1	5	1997-03-13 17:50:52
8	1	4	1996-06-05 13:37:51

ratings table

title	genres	movieId
Toy Story (1995)	Adventure Animation Children Comedy Fantasy	1
Jumanji (1995)	Adventure Children Fantasy	2
Grumpier Old Men (1995)	Comedy Romance	3

movies table

Table Relations

Cleaning - Feature Engineering

Cleaning: Συγχωνεύσαμε διπλότυπες εγγραφές στα αρχεία καθώς και αφαιρέσαμε ταινίες χωρίς αντιστοίχιση σε rating ή έτος κυκλοφορίας

Feature Engineering: Δημιουργήσαμε καινούργιες σχέσεις μεταξύ των δεδομένων


	title	genres	movied	avg_movie_rating	rating_count	rating_std	release_year	genre_count
1	Toy Story (1995)	Adventure Ani...	1	3.92124	49695	0.889012	1995	5
2	Jumanji (1995)	Adventure Chil...	2	3.21198	22243	0.95115	1995	3
3	Grumpier Old ...	Comedy Roma...	3	3.15104	12735	1.00664	1995	2

feature table

genre_count	no_genre	genre_Action	genre_Adventure	genre_Animation	genre_Children	genre_Comedy
5	0	0	1	1	1	1
3	0	0	1	0	1	0
2	0	0	0	0	0	1


final database

Statistics & Visualization



Scatter Plot


Δείχνει την μέση αξιολόγηση ταινίας ανά έτος



Distribution Diagram


Δείχνει το πλήθος αξιολογήσεων

Statistics & Visualization



Bar Plot

Πλήθος ταινιών ανά κατηγορία



Bar Plot

Μέση αξιολόγηση ταινιών ανά κατηγορία

Algorithms Application

Classification Models

- Decision Tree

Ταξινομούμε με κανόνες και χωρίζουμε τις ταινίες σε Low/Medium/High βάσει των χαρακτηριστικών τους


- Neural Network

Μαύρο κουτί με 100 κρυφούς νευρώνες το οποίο μαθαίνει να προβλέπει το `rating_class` από τα χαρακτηριστικά της ταινίας

Advanced technique

- Association Rules

Μετατρέπουμε κάθε είδος και `rating_class` σε `items`, όπου με τα `Frequent Itemsets` βρίσκουμε τους πιο συχνούς συνδυασμούς μεταξύ τους, φτιάχνοντας κανόνες και μετράμε το `lift` για να δούμε πόσο σχετίζονται μεταξύ τους.



Big Data Approach

Spark

Το spark μοιράζει τις εγγραφές του csv αρχείου σε itemsets, όπου επεξεργάζονται αυτόνομα από άλλους επεξεργαστές για να δημιουργήσουν ένα ενιαίο αποτέλεσμα. Καταφέραμε μέσω αυτού να συμπεκνώσουμε τα αρχεία από 20M σε 26.744 - πολύ κοντινό αποτέλεσμα με το manual cleaning που κάναμε εμείς.



Model Evaluation

Συγκρίναμε τα Classification Models μεταξύ τους για να βρούμε διαφορές με βάση τα Accuracy, Precision/Recall, Confusion Matrix και ROC Curve.

Decision Tree:

Accuracy = 66.8%

Precision = 64.8%

Recall = 66.8%

		Predicted			Σ
		High	Low	Medium	
Actual	High	138	238	1367	1743
	Low	36	4408	4173	8617
	Medium	157	2612	13562	16331
Σ		331	7258	19102	26691

Decision Tree
Confusion Matrix

Neural Network:

Accuracy = 67.8%


Precision = 65.8%

Recall = 67.8%


		Predicted			Σ
		High	Low	Medium	
Actual	High	115	93	1535	1743
	Low	13	3928	4676	8617
	Medium	120	2434	13777	16331
Σ		248	6455	19988	26691

Neural Network
Confusion Matrix


Decision Tree & Neural Network ROC Curves




Low



Medium



High



Model Comparison

Το Decision Tree τα πήγε ελαφρώς χειρότερα στις κατηγορίες High και Low, αλλά λίγο καλύτερα στα Medium, σε σχέση με το Neural Network. Το ίδιο φαίνεται και στα ROC curves, όπου το Neural Network δείχνει πιο σταθερή αναλογία ανάμεσα σε false positive και true positive.

Γενικά είχαμε πολύ κοντινά αποτελέσματα και στα δύο μοντέλα με το Neural Network να είναι ελάχιστα πιο αποδοτικό για το dataset μας.

Conclusion

Η ανάλυση που πραγματοποιήσαμε μας έδωσε ενδιαφέροντα στατιστικά για τις ταινίες και έδειξε κρυφές συνδέσεις ανάμεσα στις κατηγορίες και τις αξιολογήσεις τους. Αυτά τα δεδομένα μπορούν να τροφοδοτήσουν ένα *recommendation system* και ρίχνουν μια ωραία ματιά στις ταινίες των περασμένων δεκαετιών.

Thank you!