



**Πανεπιστήμιο Δυτικής Αττικής**  
**Τμήμα μηχανικών πληροφορικής και υπολογιστών**

# **Διαχείριση Δεδομένων Μεγάλης Κλίμακας**

Νικολάου Λουκάς (22390158)  
Κατεχάκης Γεώργιος (22390087)  
Χότζα Σέρτζιο (22390301)  
Κωνσταντίνος Γιακουμής (21390035)

[Github Link](#)

# Περιεχόμενα

|                                      |    |
|--------------------------------------|----|
| Dataset .....                        | 3  |
| Περιγραφή dataset .....              | 3  |
| Cleaning .....                       | 6  |
| Feature engineering .....            | 6  |
| Παρατηρήσεις .....                   | 6  |
| Τελικό Dataset .....                 | 7  |
| Διερευνητική ανάλυση δεδομένων ..... | 7  |
| Στατιστικά & Visualization .....     | 7  |
| Εφαρμογή Αλγορίθμων .....            | 9  |
| Classification Models .....          | 9  |
| Decision Tree .....                  | 9  |
| Neural Network .....                 | 10 |
| Advanced Technique .....             | 10 |
| Association Rules .....              | 10 |
| Παρατηρήσεις .....                   | 11 |
| Big Data Approach .....              | 11 |
| Spark .....                          | 11 |
| Model Evaluation .....               | 11 |
| Σύγκριση Μοντέλων .....              | 13 |

# Dataset

## Περιγραφή dataset

Χρησιμοποιήσαμε το MovieLens Dataset με 20 εκατομμύρια data entries. Το dataset χωρίζεται σε 6 αρχεία csv με την στήλη movieId και userId να μοιράζονται μέσα στους πίνακες. Τα αρχεία που έχουν ένα movieId ξεκινάνε από το 1 και ανεβαίνουν με μη σταθερό ρυθμό, αρχίζοντας να αυξάνονται κατά 1 και στην συνέχεια αυξάνονται κατά τυχαίο αριθμό.

### 1. movie

Υπάρχουν τίτλοι (title) ταινιών ξεκινώντας από το 1891 μέχρι το 2015. Το κάθε entry έχει και το είδος ή είδη (genres) όπως Drama, Comedy, etc με 246 να έχουν (no genres listed) για είδος (genres).

| title                   | genres                                      | movieId |
|-------------------------|---------------------------------------------|---------|
| Toy Story (1995)        | Adventure Animation Children Comedy Fantasy | 1       |
| Jumanji (1995)          | Adventure Children Fantasy                  | 2       |
| Grumpier Old Men (1995) | Comedy Romance                              | 3       |

### 2. tag

Περιέχει τα userId των ρηστών που έδωσαν tags στις ταινίες. Τα tag για κάθε movieId και τα timestamps που δείχνει πότε δόθηκε το tag από ένα συγκεκριμένο userId.

| tag                              | userId | movieId | timestamp           |
|----------------------------------|--------|---------|---------------------|
| 2009 reissue in Stereoscopic 3-D | 123297 | 1       | 2011-05-28 19:39:28 |
| 3D                               | 29750  | 1       | 2007-03-12 08:08:18 |
| 3D                               | 50798  | 1       | 2010-05-12 11:52:43 |

### 3. rating

Περιέχει movieIds μαζί με τους χρήστες (userId), τις αξιολογήσεις (rating) που έδωσαν και τα timestamps. Μια ταινία (MovieId) μπορεί να έχει πολλές αξιολογήσεις (rating) από πολλούς διαφορετικούς χρήστες (userId).

| userId | movieId | rating | timestamp           |
|--------|---------|--------|---------------------|
| 3      | 1       | 4      | 1999-12-11 13:36:47 |
| 6      | 1       | 5      | 1997-03-13 17:50:52 |
| 8      | 1       | 4      | 1996-06-05 13:37:51 |

#### 4. link

Το link συνδυάζει τα movieId με τα imdbid και τα tmdbid, άρα συνδέει τα identifiers των ταινιών με τα αντίστοιχα id των εξωτερικών πηγών imdb και tmdb.

| movieId | imdbid | tmdbid |
|---------|--------|--------|
| 1       | 114709 | 862    |
| 2       | 113497 | 8844   |
| 3       | 113228 | 15602  |

#### 5. genome\_tags

Τα genome\_tags περιέχουν την περιγραφή (tag) του κάθε tag (tagId).


| tag          | tagId |
|--------------|-------|
| 007          | 1     |
| 007 (series) | 2     |
| 18th century | 3     |

#### 6. genome\_scores

Τα genome\_scores περιέχουν το relevance του κάθε tag (tagId) με την κάθε ταινία (movieId). Το relevance είναι από 0 μέχρι 1.

| movieId | tagId | relevance |
|---------|-------|-----------|
| 1       | 1     | 0.025     |
| 1       | 2     | 0.025     |
| 1       | 3     | 0.05775   |

- Οι σχέσεις μεταξύ των πινάκων φαίνονται στην παρακάτω εικόνα



## Cleaning

Στην αρχή για τα αρχεία movie και rating εντοπίσαμε 16 διπλές ταινίες και αφαιρέσαμε την δεύτερη εμφάνιση, ενώνοντας τα genres, αν διέφεραν. Στην συνέχεια, στο rating αντικαταστήσαμε τα διπλότυπα movieId με αυτά που κρατήσαμε στο προηγούμενο βήμα. Ενώσαμε movie και rating, κάνοντας αντιστοίχιση κάθε ταινία με το rating του κάθε χρήστη, έχοντας αποτέλεσμα να μην επιλεγθούν ταινίες που δεν είχαν αντιστοίχιση με κανένα rating. Επιπλέον, αφαιρέσαμε ταινίες που δεν έχουν έτος κυκλοφορίας.

## Feature engineering

Με το feature engineering χρησιμοποιήσαμε το dataset για να βρούμε καινούργιες σχέσεις μεταξύ των δεδομένων.

Φτιάξαμε ένα python script που υπολογίζει το μέσο rating κάθε ταινίας (avg\_movie\_rating), πόσα rating είχε κάθε ταινία (rating\_count), πόσο κοντά ήταν τα ratings μεταξύ τους (rating\_std) και το έτος κυκλοφορίας (release\_year), πόσα είδη έχει (genre\_count). Άρα καταλήξαμε σε αυτόν τον πίνακα:

|   | title            | genres            | movieId | avg_movie_rating | rating_count | rating_std | release_year | genre_count |
|---|------------------|-------------------|---------|------------------|--------------|------------|--------------|-------------|
| 1 | Toy Story (1995) | Adventure Ani...  | 1       | 3.92124          | 49695        | 0.889012   | 1995         | 5           |
| 2 | Jumanji (1995)   | Adventure Chil... | 2       | 3.21198          | 22243        | 0.95115    | 1995         | 3           |
| 3 | Grumpier Old ... | Comedy Roma...    | 3       | 3.15104          | 12735        | 1.00664    | 1995         | 2           |

Τέλος, με βάση τα διαφορετικά είδη που υπάρχουν για τις ταινίες φτιάξαμε τον τελικό πίνακα που για κάθε είδος ταινίας δίνει τιμή 0 ή 1 στην αντίστοιχη στήλη του είδους.

| genre_count | no_genre | genre_Action | genre_Adventure | genre_Animation | genre_Children | genre_Comedy |
|-------------|----------|--------------|-----------------|-----------------|----------------|--------------|
| 5           | 0        | 0            | 1               | 1               | 1              | 1            |
| 3           | 0        | 0            | 1               | 0               | 1              | 0            |
| 2           | 0        | 0            | 0               | 0               | 0              | 1            |

## Παρατηρήσεις

- Τα βήματα του Cleaning και του Feature engineering έγιναν παράλληλα καθώς με την δημιουργία καινούργιων feature βρήκαμε πως κάποιες εγγραφές ήταν ελλιπείς.
- Αγνοήσαμε τα timestamps καθώς δεν είχαν κάποια χρήση στα στατιστικά μας δεδομένα. Επιπλέον αφαιρέσαμε τα userId καθώς είχε υπολογιστή ένα μέσο rating για κάθε ταινία από όλους τους users που είχαν κάνει rate την ταινία.


## Τελικό Dataset

Ξεκινήσαμε με ένα movie.csv που είχε 27.278 ταινίες και το rating.csv 20.000.263 rating. Καταλήξαμε με ένα αρχείο (Processed\_Dataset.tab) που έχει μόνο 26.713. Παρακάτω θα χρησιμοποιηθούν δεδομένα μόνο από το αυτό το αρχείο.


## Διερευνητική ανάλυση δεδομένων

### Στατιστικά & Visualization


Τα διαγράμματα που ακολουθούν είναι μια αναπαράσταση των στατιστικών δεδομένων του dataset.



- Το παραπάνω διάγραμμα scatterplot δείχνει την μέση αξιολόγηση κάθε ταινίας προς τον χρόνο που κυκλοφόρησε. Για κάθε δεκαετία μετά το 1950 δίνετε διαφορετικό χρώμα.




- Εδώ φαίνεται το πλήθος των αξιολογήσεων που έχουν δοθεί.



- Σε αυτό το διάγραμμα φαίνεται το πλήθος των ταινιών που ανήκουν σε κάθε είδος.





- Το παραπάνω διάγραμμα δείχνει την μέση αξιολόγηση των ταινιών που ανήκουν σε κάθε είδος.

## Εφαρμογή Αλγορίθμων

Για Classification models χρησιμοποιήθηκε το Decision Tree και το Neural Network. Για advance technique χρησιμοποιήθηκε το Association Rules.

## Classification Models

### Decision Tree

Για το Decision Tree χρειάστηκε να διαχωρίσουμε τις ταινίες με βάση την μέση αξιολόγηση τους. Οι ταινίες χαρακτηρίστηκαν :


‘Low’ για  $0 \leq \text{avg\_movie\_rating} < 3$ ,

‘Medium’ για  $3 \leq \text{avg\_movie\_rating} < 4$ ,

‘High’ για  $4 \leq \text{avg\_movie\_rating} \leq 5$ .

Επομένως προσθέσαμε στον πίνακα την νέα στήλη rating\_class. Στην συνέχεια χρησιμοποιήσαμε το rating\_class ως target του Decision Tree και κρύψαμε την μέση αξιολόγηση κάθε ταινίας. Επομένως, δημιουργήθηκε ένα Decision Tree που προσπαθεί να προβλέψει αν μια ταινία θα χαρακτηρίζεται ως Low, Medium

ή High, μόνο από τα genres, rating\_count, genre\_count, release\_year και rating\_std.



Στην εικόνα φαίνεται ένα κομμάτι του δέντρου. Κάθε φύλλο αντιστοιχεί στην κατηγορία στην οποία κατατάσσεται μια ταινία με βάση τα κριτήρια στο οποία περνάει στα πιο πάνω επίπεδα. Το ποσοστό σε κάθε φύλλο δίνει εμπιστοσύνη της πρόβλεψης για αυτή την κατηγοριοποίηση. Αν το χρώμα είναι κόκκινο χαρακτηρίζεται Low, πράσινο αν είναι Medium και μπλε αν είναι High. Όσο πιο σίγουρο για την πρόβλεψη της κατηγοριοποίησης, τόσο πιο έντονο το χρώμα του φύλλου.

## Neural Network

Το Νευρωνικό δίκτυο είναι ένα μαύρο κουτί. Δώσαμε rating\_count, genre\_count, τα genres και το release\_year. Ως στόχο έχει να υπολογίσει το rating\_class όπως και το δέντρο παραπάνω. Έτσι, δημιουργήθηκε ένα νευρωνικό δίκτυο, με 100 κρυφούς νευρώνες, activation ReLU και ο αλγόριθμος βελτιστοποίησης Adam, με μέγιστο αριθμό επαναλήψεων τους 200.

## Advanced Technique

### Association Rules

Η τεχνική του Association Rules υλοποιήθηκε με την χρήση της python βιβλιοθήκης Associate. Πέρασαμε τα genres από ένα python script που για κάθε είδος ταινίας που το περιέχει βάζει “yes”. Στην συνέχεια εντοπίσαμε τους πιο συχνούς συνδυασμούς ειδών που υπήρχαν μεταξύ των ταινιών, για να δημιουργήσουμε κανόνες. Δημιουργούνται κανόνες (association rules) μεταξύ των genres και εντοπίζει αυτά που έχουν περισσότερες κοινές ταινίες.

## Παρατηρήσεις

Αρχικά θέλαμε να φτιάξουμε ένα recommendation system, αλλά λόγω του όγκου του Dataset ήταν δύσκολο να διαχειριστούμε όλα τα δεδομένα.

Επομένως, επιλέξαμε να χρησιμοποιήσουμε Association Rules.

## Big Data Approach

### Spark

[Things here]

## Model Evaluation

Συγκρίναμε τις αποδόσεις των μοντέλων Decision Tree και Neural Network, με βάση τα Accuracy, Precision/Recall, Confusion Matrix και ROC Curve. Το Accuracy δείχνει τις σωστές κατηγοριοποιήσεις, το Precision μετράει τα false alarms, το Recall πόσα δεν κατηγοριοποίησε σωστά, στο Confusion Matrix φαίνονται οι διαφορές στην κατηγοριοποίηση που δόθηκε σε σχέση με την πραγματική και στο ROC Curve δείχνει την αναλογία μεταξύ των false positive και των true positive.

| Model          | CA    | Prec  | Recall |
|----------------|-------|-------|--------|
| Tree           | 0.668 | 0.648 | 0.668  |
| Neural Network | 0.678 | 0.658 | 0.678  |

- Για το Decision Tree: Το Accuracy (CA) είναι 66.8%, το Precision (Prec) 64.8% και το Recall 66.8%.
- Για το Neural Network: Το Accuracy (CA) είναι 67.8%, το Precision (Prec) 65.8% και το Recall 67.8%.
- Τα Confusion Matrix:


|        |        | Predicted |      |        | Σ     |
|--------|--------|-----------|------|--------|-------|
|        |        | High      | Low  | Medium |       |
| Actual | High   | 115       | 93   | 1535   | 1743  |
|        | Low    | 13        | 3928 | 4676   | 8617  |
|        | Medium | 120       | 2434 | 13777  | 16331 |
| Σ      |        | 248       | 6455 | 19988  | 26691 |

*Decision Tree*


|        |        | Predicted |      |        | Σ     |
|--------|--------|-----------|------|--------|-------|
|        |        | High      | Low  | Medium |       |
| Actual | High   | 138       | 238  | 1367   | 1743  |
|        | Low    | 36        | 4408 | 4173   | 8617  |
|        | Medium | 157       | 2612 | 13562  | 16331 |
| Σ      |        | 331       | 7258 | 19102  | 26691 |

*Neural Network*


- Το ROC Curve για Decision Tree και Neural Network:



*Low*



*Medium*



*High*

## Σύγκριση Μοντέλων

Τα μοντέλα Decision Tree και Neural Network, είχαν σχεδόν ίδια αποτελέσματα σε Accuracy, Precision και Recall, με το Neural Network να είναι 1% καλύτερο σταθερά. Το Confusion Matrix στο Decision Tree δείχνει ότι ήταν ελάχιστα χειρότερο στην κατηγοριοποίηση των High και Low, αλλά ελάχιστα καλύτερο στα Medium, συγκριτικά με το Neural Network. Αυτό φαίνεται και στο ROC Curve που δείχνει πως το Neural Network είναι πιο σταθερό, δηλαδή έχει πιο σταθερή αναλογία μεταξύ των false positive και true positive.

Επομένως, τα μοντέλα είχαν κοντινή απόδοση για το dataset που δημιουργήσαμε, με το Neural Network να είναι ελάχιστα πιο αποδοτικό.