



Πανεπιστήμιο Δυτικής Αττικής
Τμήμα μηχανικών πληροφορικής και υπολογιστών

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Νικολάου Λουκάς (22390158)
Κατεχάκης Γεώργιος (22390087)
Χότζα Σέρτζιο (22390301)
Κωνσταντίνος Γιακουμής (21390035)

[Github Link](#)

Περιεχόμενα

Dataset	3
Περιγραφή dataset	3
Cleaning	6
Feature engineering	6
Παρατηρήσεις	6
Τελικό Dataset	7
Διερευνητική ανάλυση δεδομένων	7
Στατιστικά & Visualization	7
Εφαρμογή Αλγορίθμων	9
Classification Models	9
Decision Tree	9
Neural Network	10

Dataset

Περιγραφή dataset

Χρησιμοποιήσαμε το MovieLens Dataset με 20 data entries. Το dataset χωρίζεται σε 6 αρχεία csv με την στήλη movieId και userId να μοιράζονται μέσα στους πίνακες. Τα αρχεία που έχουν ένα movieId ξεκινάνε από το 1 και ανεβαίνουν με μη σταθερό ρυθμό, αρχίζοντας να αυξάνονται κατά 1 και στην συνέχεια αυξάνονται κατά τυχαίο αριθμό.

1. movie

Υπάρχουν τίτλοι (title) ταινιών ξεκινώντας από το 1891 μέχρι το 2015. Το κάθε entry έχει και το είδος ή είδη (genres) όπως Drama, Comedy, etc με 246 να έχουν (no genres listed) για είδος (genres).

title	genres	movieId
Toy Story (1995)	Adventure Animation Children Comedy Fantasy	1
Jumanji (1995)	Adventure Children Fantasy	2
Grumpier Old Men (1995)	Comedy Romance	3

2. tag

Περιέχει τα userId των ρηστών που έδωσαν tags στις ταινίες. Τα tag για κάθε movieId και τα timestamps που δείχνει πότε δόθηκε το tag από ένα συγκεκριμένο userId.

tag	userId	movieId	timestamp
2009 reissue in Stereoscopic 3-D	123297	1	2011-05-28 19:39:28
3D	29750	1	2007-03-12 08:08:18
3D	50798	1	2010-05-12 11:52:43

3. rating

Περιέχει movieIds μαζί με τους χρήστες (userId), τις αξιολογήσεις (rating) που έδωσαν και τα timestamps. Μια ταινία (MovieId) μπορεί να έχει πολλές αξιολογήσεις (rating) από πολλούς διαφορετικούς χρήστες (userId).

userId	movieId	rating	timestamp
3	1	4	1999-12-11 13:36:47
6	1	5	1997-03-13 17:50:52
8	1	4	1996-06-05 13:37:51

4. link

Το link συνδυάζει τα movieId με τα imdbid και τα tmdbid, άρα συνδέει τα identifiers των ταινιών με τα αντίστοιχα id των εξωτερικών πηγών imdb και tmdb.

movieId	imdbid	tmdbid
1	114709	862
2	113497	8844
3	113228	15602

5. genome_tags

Τα genome_tags περιέχουν την περιγραφή (tag) του κάθε tag (tagId).


tag	tagId
007	1
007 (series)	2
18th century	3

6. genome_scores

Τα genome_scores περιέχουν το relevance του κάθε tag (tagId) με την κάθε ταινία (movieId). Το relevance είναι από 0 μέχρι 1.

movieId	tagId	relevance
1	1	0.025
1	2	0.025
1	3	0.05775

- Οι σχέσεις μεταξύ των πινάκων φαίνονται στην παρακάτω εικόνα



Cleaning

Στην αρχή για τα αρχεία `movie` και `rating` εντοπίσαμε 16 διπλές ταινίες και αφαιρέσαμε την δεύτερη εμφάνιση, ενώνοντας τα `genres`, αν διέφεραν. Στην συνέχεια, στο `rating` αντικαταστήσαμε τα διπλότυπα `movieId` με αυτά που κρατήσαμε στο προηγούμενο βήμα. Ενώσαμε `movie` και `rating`, κάνοντας αντιστοίχιση κάθε ταινία με το `rating` του κάθε χρήστη, έχοντας αποτέλεσμα να μην επιλεγθούν ταινίες που δεν είχαν αντιστοίχιση με κανένα `rating`. Επιπλέον, αφαιρέσαμε ταινίες που δεν έχουν έτος κυκλοφορίας.

Feature engineering

Με το `feature engineering` χρησιμοποιήσαμε το `dataset` για να βρούμε καινούργιες σχέσεις μεταξύ των δεδομένων.

Φτιάξαμε ένα `python script` που υπολογίζει το μέσο `rating` κάθε ταινίας (`avg_movie_rating`), πόσα `rating` είχε κάθε ταινία (`rating_count`), πόσο κοντά ήταν τα `ratings` μεταξύ τους (`rating_std`) και το έτος κυκλοφορίας (`release_year`), πόσα είδη έχει (`genre_count`). Άρα καταλήξαμε σε αυτόν τον πίνακα:

	title	genres	movieId	avg_movie_rating	rating_count	rating_std	release_year	genre_count
1	Toy Story (1995)	Adventure Ani...	1	3.92124	49695	0.889012	1995	5
2	Jumanji (1995)	Adventure Chil...	2	3.21198	22243	0.95115	1995	3
3	Grumpier Old ...	Comedy Roma...	3	3.15104	12735	1.00664	1995	2

Τέλος, με βάση τα διαφορετικά είδη που υπάρχουν για τις ταινίες φτιάξαμε τον τελικό πίνακα που για κάθε είδος ταινίας δίνει τιμή 0 ή 1 στην αντίστοιχη στήλη του είδους.

genre_count	no_genre	genre_Action	genre_Adventure	genre_Animation	genre_Children	genre_Comedy
5	0	0	1	1	1	1
3	0	0	1	0	1	0
2	0	0	0	0	0	1

Παρατηρήσεις

- Τα βήματα του `Cleaning` και του `Feature engineering` έγιναν παράλληλα καθώς με την δημιουργία καινούργιων `feature` βρήκαμε πως κάποιες εγγραφές ήταν ελλιπείς.
- Αγνοήσαμε τα `timestamps` καθώς δεν είχαν κάποια χρήση στα στατιστικά μας δεδομένα. Επιπλέον αφαιρέσαμε τα `userId` καθώς είχε υπολογιστή ένα μέσο `rating` για κάθε ταινία από όλους τους `users` που είχαν κάνει `rate` την ταινία.


Τελικό Dataset

Ξεκινήσαμε με ένα movie.csv που είχε 27.278 ταινίες και το rating.csv 20.000.263 rating. Καταλήξαμε με ένα αρχείο (Processed_Dataset.tab) που έχει μόνο 26.713. Παρακάτω θα χρησιμοποιηθούν δεδομένα μόνο από το αυτό το αρχείο.


Διερευνητική ανάλυση δεδομένων

Στατιστικά & Visualization


Τα διαγράμματα που ακολουθούν είναι μια αναπαράσταση των στατιστικών δεδομένων του dataset.




- Το παραπάνω διάγραμμα scatterplot δείχνει την μέση αξιολόγηση κάθε ταινίας προς τον χρόνο που κυκλοφόρησε. Για κάθε δεκαετία μετά το 1950 δίνετε διαφορετικό χρώμα.



- Εδώ φαίνεται το πλήθος των αξιολογήσεων που έχουν δοθεί.



- Σε αυτό το διάγραμμα φαίνεται το πλήθος των ταινιών που ανήκουν σε κάθε είδος.



- Το παραπάνω διάγραμμα δείχνει την μέση αξιολόγηση των ταινιών που ανήκουν σε κάθε είδος.

Εφαρμογή Αλγορίθμων

Για Classification models χρησιμοποιήθηκε το Decision Tree και το Neural Network. Για advance technique χρησιμοποιήθηκε [To be continued].

Classification Models

Decision Tree

Για το Decision Tree χρειάστηκε να διαχωρίσουμε τις ταινίες με βάση την μέση αξιολόγηση τους. Οι ταινίες χαρακτηρίστηκαν :


‘Low’ για $0 \leq \text{avg_movie_rating} < 3$,

‘Medium’ για $3 \leq \text{avg_movie_rating} < 4$,

‘High’ για $4 \leq \text{avg_movie_rating} \leq 5$.

Επομένως προσθέσαμε στον πίνακα την νέα στήλη rating_class. Στην συνέχεια χρησιμοποιήσαμε το rating_class ως target του Decision Tree, κρύψαμε την μέση αξιολόγηση κάθε ταινίας και (avg_movie_rating) και την απόκλιση των αξιολογήσεων (rating_std). Επομένως, δημιουργήθηκε ένα Decision Tree που

προσπαθεί να προβλέψει αν μια ταινία θα χαρακτηρίζεται ως Low, Medium ή High, μόνο από τα genres, rating_count, genre_count και release_year.



Στην εικόνα φαίνεται ένα κομμάτι του δέντρου. Κάθε φύλλο αντιστοιχεί στην κατηγορία στην οποία κατατάσσεται μια ταινία με βάση τα κριτήρια στο οποία περνάει στα πιο πάνω επίπεδα. Το ποσοστό σε κάθε φύλλο δίνει εμπιστοσύνη της πρόβλεψης για αυτή την κατηγοριοποίηση. Αν το χρώμα είναι κόκκινο χαρακτηρίζεται Low, πράσινο αν είναι Medium και μπλε αν είναι High. Όσο πιο σίγουρο για την πρόβλεψη της κατηγοριοποίησης, τόσο πιο έντονο το χρώμα του φύλλου.

Neural Network