



Πανεπιστήμιο Δυτικής Αττικής
Τμήμα μηχανικών πληροφορικής και υπολογιστών

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Νικολάου Λουκάς (22390158)
Κατεχάκης Γεώργιος (22390087)
Χότζα Σέρτζιο (22390301)
Γιακουμής Κωνσταντίνος (21390035)

[Github Link](#)

Περιεχόμενα

Dataset	3
Περιγραφή dataset	3
Cleaning	6
Feature engineering	6
Παρατηρήσεις	6
Τελικό Dataset	7
Διερευνητική ανάλυση δεδομένων	7
Στατιστικά & Visualization	7
Εφαρμογή Αλγορίθμων	9
Classification Models	9
Decision Tree	9
Neural Network	10
Advanced Technique	10
Association Rules	10
Παρατηρήσεις	11
Big Data Approach	11
Spark	11
Παρατηρήσεις	12
Model Evaluation	12
Σύγκριση Μοντέλων	14
Συμπεράσματα	14
Κατανομή ρόλων	14

Dataset

Περιγραφή dataset

Χρησιμοποιήσαμε το MovieLens Dataset με 20 εκατομμύρια data entries. Το dataset χωρίζεται σε 6 αρχεία csv με την στήλη movieId και userId να μοιράζονται μέσα στους πίνακες. Τα αρχεία που έχουν ένα movieId ξεκινάνε από το 1 και ανεβαίνουν με μη σταθερό ρυθμό, αρχίζοντας να αυξάνονται κατά 1 και στην συνέχεια αυξάνονται κατά τυχαίο αριθμό.

1. movie

Υπάρχουν τίτλοι (title) ταινιών ξεκινώντας από το 1891 μέχρι το 2015. Το κάθε entry έχει και το είδος ή είδη (genres) όπως Drama, Comedy, etc με 246 να έχουν (no genres listed) για είδος (genres).

title	genres	movieId
Toy Story (1995)	Adventure Animation Children Comedy Fantasy	1
Jumanji (1995)	Adventure Children Fantasy	2
Grumpier Old Men (1995)	Comedy Romance	3

2. tag

Περιέχει τα userId των χρηστών που έδωσαν tags στις ταινίες. Τα tag για κάθε movieId και τα timestamps που δείχνει πότε δόθηκε το tag από ένα συγκεκριμένο userId.

tag	userId	movieId	timestamp
2009 reissue in Stereoscopic 3-D	123297	1	2011-05-28 19:39:28
3D	29750	1	2007-03-12 08:08:18
3D	50798	1	2010-05-12 11:52:43

3. rating

Περιέχει movieIds μαζί με τους χρήστες (userId), τις αξιολογήσεις (rating) που έδωσαν και τα timestamps. Μια ταινία (MovieId) μπορεί να έχει πολλές αξιολογήσεις (rating) από πολλούς διαφορετικούς χρήστες (userId).

userId	movieId	rating	timestamp
3	1	4	1999-12-11 13:36:47
6	1	5	1997-03-13 17:50:52
8	1	4	1996-06-05 13:37:51

4. link

Το link συνδυάζει τα movieId με τα imdbid και τα tmdbid, άρα συνδέει τα identifiers των ταινιών με τα αντίστοιχα id των εξωτερικών πηγών imdb και tmdb.

movieId	imdbid	tmdbid
1	114709	862
2	113497	8844
3	113228	15602

5. genome_tags

Τα genome_tags περιέχουν την περιγραφή (tag) του κάθε tag (tagId).


tag	tagId
007	1
007 (series)	2
18th century	3

6. genome_scores

Τα genome_scores περιέχουν το relevance του κάθε tag (tagId) με την κάθε ταινία (movieId). Το relevance είναι από 0 μέχρι 1.

movieId	tagId	relevance
1	1	0.025
1	2	0.025
1	3	0.05775

- Οι σχέσεις μεταξύ των πινάκων φαίνονται στην παρακάτω εικόνα



Cleaning

Στην αρχή για τα αρχεία movie και rating εντοπίσαμε 16 διπλές ταινίες και αφαιρέσαμε την δεύτερη εμφάνιση, ενώνοντας τα genres, αν διέφεραν. Στην συνέχεια, στο rating αντικαταστήσαμε τα διπλότυπα movieId με αυτά που κρατήσαμε στο προηγούμενο βήμα. Ενώσαμε movie και rating, κάνοντας αντιστοίχιση κάθε ταινία με το rating του κάθε χρήστη, έχοντας αποτέλεσμα να μην επιλεγθούν ταινίες που δεν είχαν αντιστοίχιση με κανένα rating. Επιπλέον, αφαιρέσαμε ταινίες που δεν έχουν έτος κυκλοφορίας.

Feature engineering

Με το feature engineering χρησιμοποιήσαμε το dataset για να βρούμε καινούργιες σχέσεις μεταξύ των δεδομένων.

Φτιάξαμε ένα python script που υπολογίζει το μέσο rating κάθε ταινίας (avg_movie_rating), πόσα rating είχε κάθε ταινία (rating_count), πόσο κοντά ήταν τα ratings μεταξύ τους (rating_std), το έτος κυκλοφορίας (release_year) και πόσα είδη έχει (genre_count). Άρα καταλήξαμε σε αυτόν τον πίνακα:

	title	genres	movieId	avg_movie_rating	rating_count	rating_std	release_year	genre_count
1	Toy Story (1995)	Adventure Ani...	1	3.92124	49695	0.889012	1995	5
2	Jumanji (1995)	Adventure Chil...	2	3.21198	22243	0.95115	1995	3
3	Grumpier Old ...	Comedy Roma...	3	3.15104	12735	1.00664	1995	2

Τέλος, με βάση τα διαφορετικά είδη που υπάρχουν για τις ταινίες φτιάξαμε τον τελικό πίνακα που για κάθε είδος ταινίας δίνει τιμή 0 ή 1 στην αντίστοιχη στήλη του είδους.

genre_count	no_genre	genre_Action	genre_Adventure	genre_Animation	genre_Children	genre_Comedy
5	0	0	1	1	1	1
3	0	0	1	0	1	0
2	0	0	0	0	0	1

Παρατηρήσεις

- Τα βήματα του Cleaning και του Feature engineering έγιναν παράλληλα καθώς με την δημιουργία καινούργιων feature βρήκαμε πως κάποιες εγγραφές ήταν ελλιπείς.
- Αγνοήσαμε τα timestamps καθώς δεν είχαν κάποια χρήση στα στατιστικά μας δεδομένα. Επιπλέον αφαιρέσαμε τα userId καθώς είχε υπολογιστή ένα μέσο rating για κάθε ταινία από όλους τους users που είχαν κάνει rate την ταινία.


Τελικό Dataset

Ξεκινήσαμε με ένα movie.csv που είχε 27.278 ταινίες και το rating.csv 20.000.263 ratings. Καταλήξαμε με ένα αρχείο (Processed_Movies.tab) που έχει μόνο 26.691 εγγραφές. Παρακάτω θα χρησιμοποιηθούν δεδομένα μόνο από το αυτό το αρχείο.


Διερευνητική ανάλυση δεδομένων

Στατιστικά & Visualization


Τα διαγράμματα που ακολουθούν είναι μια αναπαράσταση των στατιστικών δεδομένων του dataset.




- Το παραπάνω διάγραμμα scatterplot δείχνει την μέση αξιολόγηση κάθε ταινίας προς τον χρόνο που κυκλοφόρησε. Για κάθε δεκαετία μετά το 1950 δίνετε διαφορετικό χρώμα.



- Εδώ φαίνεται το πλήθος των αξιολογήσεων που έχουν δοθεί.



- Σε αυτό το διάγραμμα φαίνεται το πλήθος των ταινιών που ανήκουν σε κάθε είδος.



- Το παραπάνω διάγραμμα δείχνει την μέση αξιολόγηση των ταινιών που ανήκουν σε κάθε είδος.

Εφαρμογή Αλγορίθμων

Για Classification Models χρησιμοποιήθηκε το Decision Tree και το Neural Network. Για Advanced Technique χρησιμοποιήθηκε το Association Rules.

Classification Models

Decision Tree

Για το Decision Tree χρειάστηκε να διαχωρίσουμε τις ταινίες με βάση την μέση αξιολόγηση τους. Οι ταινίες χαρακτηρίστηκαν :


‘Low’ για $0 \leq \text{avg_movie_rating} < 3$,

‘Medium’ για $3 \leq \text{avg_movie_rating} < 4$,

‘High’ για $4 \leq \text{avg_movie_rating} \leq 5$.

Επομένως προσθέσαμε στον πίνακα την νέα στήλη rating_class. Στην συνέχεια χρησιμοποιήσαμε το rating_class ως target του Decision Tree και κρύψαμε την μέση αξιολόγηση κάθε ταινίας. Επομένως, δημιουργήθηκε ένα Decision Tree που προσπαθεί να προβλέψει αν μια ταινία θα χαρακτηρίζεται ως Low, Medium

ή High, μόνο από τα genres, rating_count, genre_count, release_year και rating_std.



Στην εικόνα φαίνεται ένα κομμάτι του δέντρου. Κάθε φύλλο αντιστοιχεί στην κατηγορία στην οποία κατατάσσεται μια ταινία με βάση τα κριτήρια στο οποία περνάει στα πιο πάνω επίπεδα. Το ποσοστό σε κάθε φύλλο δίνει εμπιστοσύνη της πρόβλεψης για αυτή την κατηγοριοποίηση. Αν το χρώμα είναι κόκκινο χαρακτηρίζεται Low, πράσινο αν είναι Medium και μπλε αν είναι High. Όσο πιο σίγουρο για την πρόβλεψη της κατηγοριοποίησης, τόσο πιο έντονο το χρώμα του φύλλου.

Neural Network

Το Νευρωνικό δίκτυο είναι ένα μαύρο κουτί. Δώσαμε rating_count, rating_std, genre_count, τα genres και το release_year. Ως στόχο έχει να υπολογίσει το rating_class όπως και το δέντρο παραπάνω. Έτσι, δημιουργήθηκε ένα νευρωνικό δίκτυο, με 100 κρυφούς νευρώνες, activation ReLU και ο αλγόριθμος βελτιστοποίησης Adam, με μέγιστο αριθμό επαναλήψεων τους 200.

Advanced Technique

Association Rules

Η τεχνική του Association Rules υλοποιήθηκε με την χρήση της python βιβλιοθήκης Associate. Πέρασαμε τα genres και τα rating_class από ένα python script που για κάθε είδος ταινίας που το περιέχει βάζει “yes” και για κάθε rating_class (Low/Medium/High) τους αντιστοιχεί μια διακριτή τιμή. Στην συνέχεια εντοπίσαμε τους πιο συχνούς συνδυασμούς ειδών που υπήρχαν μεταξύ των ταινιών, για να δημιουργήσουμε κανόνες. Δημιουργούνται κανόνες (association rules) μεταξύ των genres και εντοπίζει αυτά που έχουν περισσότερες κοινές ταινίες.

Itemsets	Support	%	Supp	Conf	Covr	Strg	Lift	Levr	Antecedent	Consequent
Rating=Medium	16331	61.19	0.036	0.418	0.085	1.516	3.228	0.025	genre_Adventure=yes	→ genre_Action=yes
▼ genre_Drama=yes	13041	48.86	0.045	0.420	0.108	1.429	2.719	0.029	genre_Crime=yes	→ genre_Thriller=yes
Rating=Medium	9112	34.14	0.040	0.411	0.097	1.595	2.663	0.025	genre_Horror=yes	→ genre_Thriller=yes
Rating=Low	3017	11.3	0.041	0.317	0.130	1.192	2.052	0.021	genre_Action=yes	→ genre_Thriller=yes
▼ genre_Thriller=yes	1839	6.89	0.059	0.604	0.097	3.332	1.871	0.027	genre_Horror=yes	→ Rating=Low
Rating=Low	579	2.169	0.033	0.747	0.044	11.118	1.528	0.011	genre_War=yes	→ genre_Drama=yes
Rating=Medium	1175	4.402	0.032	0.492	0.064	5.030	1.523	0.011	genre_Sci-Fi=yes	→ Rating=Low
> genre_Romance=yes	2505	9.385	0.069	0.460	0.151	2.043	1.495	0.023	genre_Romance=yes	→ genre_Comedy=yes
Rating=High	912	3.417	0.045	0.439	0.102	3.018	1.425	0.013	genre_Romance=yes, Rating=Medium	→ genre_Comedy=yes
genre_Mystery=yes	715	2.679	0.068	0.662	0.102	4.791	1.355	0.018	genre_Romance=yes, Rating=Medium	→ genre_Drama=yes
genre_War=yes	876	3.282	0.055	0.426	0.130	2.490	1.320	0.013	genre_Action=yes	→ Rating=Low
Rating=Low	8617	32.28	0.068	0.448	0.151	2.266	1.313	0.016	genre_Romance=yes	→ genre_Drama=yes, Rating=Low
> genre_Comedy=yes	8216	30.78	0.044	0.630	0.070	6.951	1.288	0.010	genre_Crime=yes, Rating=Medium	→ genre_Drama=yes
			0.094	0.623	0.151	3.243	1.275	0.020	genre_Romance=yes	→ genre_Drama=yes
			0.063	0.405	0.155	2.089	1.255	0.013	genre_Thriller=yes	→ Rating=Low
			0.044	0.409	0.108	3.158	1.199	0.007	genre_Crime=yes	→ genre_Drama=yes, Rating=Low
			0.032	0.732	0.044	12.822	1.107	0.005	genre_War=yes	→ Rating=Medium

Frequent Itemsets

Association Rules

Το Frequent Itemsets εντοπίζει τους πιο συχνούς συνδυασμούς όλων των genres και των rating_class μεταξύ τους. Το Association Rules χρησιμοποιεί τα δεδομένα που βρίσκει το Frequent Itemsets και συνδυάζει τα genres και rating_class μεταξύ τους για να υπολογίσει το lift, το οποίο δείχνει πόσο πιο συχνά εμφανίζονται μαζί δύο στοιχεία σε σχέση με το αν ήταν εντελώς ανεξάρτητα μεταξύ τους. Αν το lift είναι 1, δεν υπάρχει σχέση μεταξύ των στοιχείων του itemset, αν είναι μικρότερο του 1 υπάρχει αρνητική συσχέτιση και αν είναι μεγαλύτερο του 1 υπάρχει αυξημένη συσχέτιση.

Παρατηρήσεις

Αρχικά θέλαμε να φτιάξουμε ένα recommendation system, αλλά λόγω του όγκου του Dataset ήταν δύσκολο να διαχειριστούμε όλα τα δεδομένα. Επομένως, επιλέξαμε να χρησιμοποιήσουμε Association Rules.

Big Data Approach

Spark

Το spark λειτουργεί μοιράζοντας τις εγγραφές του csv αρχείου σε itemsets, όπου επεξεργάζονται αυτόνομα από άλλους επεξεργαστές και στο τέλος δημιουργούν ένα ενιαίο αποτέλεσμα.

Με την χρήση της βιβλιοθήκης pyspark καταφέραμε να καθαρίσουμε τον μεγάλο όγκο δεδομένων και τα φέραμε στα 26.744, που είναι 53 αρχεία περισσότερα από το δικό μας cleaning process. Άρα το αρχείο spark_movie_agg.csv έχει τα αποτελέσματα του script και θα μπορούσε να χρησιμοποιηθεί αντί για το Processed_Movies.tab.

```
BigDataAnalysis main !1 > python3 spark.py
Picked up _JAVA_OPTIONS: -Dawt.useSystemAAFontSettings=on -Dswing.aatext=true
Picked up _JAVA_OPTIONS: -Dawt.useSystemAAFontSettings=on -Dswing.aatext=true
WARNING: Using incubator modules: jdk.incubator.vector
Using Spark's default log4j profile: org/apache/spark/log4j2-defaults.properties
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
26/06/11 23:29:37 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Shrunk 20,000,263 ratings -> 26744
BigDataAnalysis main !1 >
```

Παρατηρήσεις

- Το spark.py έτρεξε σε μηχανήμα linux και το αποτέλεσμα φαίνεται στην παραπάνω εικόνα.

Model Evaluation

Συγκρίναμε τις αποδόσεις των μοντέλων Decision Tree και Neural Network, με βάση τα Accuracy, Precision/Recall, Confusion Matrix και ROC Curve. Το Accuracy δείχνει τις σωστές κατηγοριοποιήσεις, το Precision μετράει την σχέση των σωστών προβλέψεων προς τις συνολικές προβλέψεις, το Recall πόσα κατηγοριοποίησε σωστά, στο Confusion Matrix φαίνονται οι διαφορές στην κατηγοριοποίηση που δόθηκε σε σχέση με την πραγματική και στο ROC Curve δείχνει την αναλογία μεταξύ των false positive και των true positive.

Model	CA	Prec	Recall
Tree	0.668	0.648	0.668
Neural Network	0.678	0.658	0.678

- Για το Decision Tree: Το Accuracy (CA) είναι 66.8%, το Precision (Prec) 64.8% και το Recall 66.8%.
- Για το Neural Network: Το Accuracy (CA) είναι 67.8%, το Precision (Prec) 65.8% και το Recall 67.8%.
- Τα Confusion Matrix:


		Predicted			Σ
		High	Low	Medium	
Actual	High	115	93	1535	1743
	Low	13	3928	4676	8617
	Medium	120	2434	13777	16331
Σ		248	6455	19988	26691

Decision Tree


		Predicted			Σ
		High	Low	Medium	
Actual	High	138	238	1367	1743
	Low	36	4408	4173	8617
	Medium	157	2612	13562	16331
Σ		331	7258	19102	26691

Neural Network


- Το ROC Curve για **Decision Tree** και **Neural Network**:



Low



Medium



High

Σύγκριση Μοντέλων

Τα μοντέλα Decision Tree και Neural Network, είχαν σχεδόν ίδια αποτελέσματα σε Accuracy, Precision και Recall, με το Neural Network να είναι 1% καλύτερο σταθερά. Το Confusion Matrix στο Decision Tree δείχνει ότι ήταν ελάχιστα χειρότερο στην κατηγοριοποίηση των High και Low, αλλά ελάχιστα καλύτερο στα Medium, συγκριτικά με το Neural Network. Αυτό φαίνεται και στο ROC Curve που δείχνει πως το Neural Network είναι πιο σταθερό, δηλαδή έχει πιο σταθερή αναλογία μεταξύ των false positive και true positive.

Επομένως, τα μοντέλα είχαν κοντινή απόδοση για το dataset που δημιουργήσαμε, με το Neural Network να είναι ελάχιστα πιο αποδοτικό.

Συμπεράσματα

Η ανάλυση του dataset μας έδωσε πληροφορίες για της ταινίες και βρήκε ενδιαφέροντα στατιστικά στοιχεία με βάση τις αξιολογήσεις των χρηστών. Επιπλέον, ανακαλύφθηκαν συνδέσεις μεταξύ των ειδών, των ταινιών και των αξιολογήσεων τους.

Τα δεδομένα που βρέθηκαν είναι χρήσιμα για την ένταξη τους σε ένα εξωτερικό recommendation system (ειδικά το Association Rules) και προσφέρουν μια ενδιαφέρουσα οπτική γωνία ως προς τις ταινίες των προηγούμενων δεκαετιών.

Κατανομή ρόλων

- Νικολάου Λουκάς - Data Engineer
- Κατεχάκης Γεώργιος - Data Analyst
- Χότζα Σέρτζιο - ML Engineer
- Κωνσταντίνος Γιακουμής - ML Engineer