



Πανεπιστήμιο Δυτικής Αττικής
Τμήμα μηχανικών πληροφορικής και υπολογιστών

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Νικολάου Λουκάς (22390158)
Κατεχάκης Γεώργιος (22390087)
Χότζα Σέρτζιο (22390301)
Κωνσταντίνος Γιακουμής (21390035)

[Github Link](#)

Περιεχόμενα

Dataset	3
Περιγραφή dataset	3
Cleaning	6
Feature engineering	6
Παρατηρήσεις	7
Διερευνητική ανάλυση δεδομένων	7
Στατιστικά & Visualization	7

Dataset

Περιγραφή dataset

Χρησιμοποιήσαμε το MovieLens Dataset με 20 data entries. Το dataset χωρίζεται σε 6 αρχεία csv με την στήλη movieId και userId να μοιράζονται μέσα στους πίνακες. Τα αρχεία που έχουν ένα movieId ξεκινάνε από το 1 και ανεβαίνουν με μη σταθερό ρυθμό, αρχίζοντας να αυξάνονται κατά 1 και στην συνέχεια αυξάνονται κατά τυχαίο αριθμό.

1. movie

Υπάρχουν τίτλοι (title) ταινιών ξεκινώντας από το 1891 μέχρι το 2015. Το κάθε entry έχει και το είδος ή είδη (genres) όπως Drama, Comedy, etc με 246 να έχουν (no genres) για είδος (genres).

title	genres	movieId
Toy Story (1995)	Adventure Animation Children Comedy Fantasy	1
Jumanji (1995)	Adventure Children Fantasy	2
Grumpier Old Men (1995)	Comedy Romance	3

2. tag

Περιέχει τα userId των ρηστών που έδωσαν tags στις ταινίες. Τα tag για κάθε movieId και τα timestamps που δείχνει πότε δόθηκε το tag από ένα συγκεκριμένο userId.

tag	userId	movieId	timestamp
2009 reissue in Stereoscopic 3-D	123297	1	2011-05-28 19:39:28
3D	29750	1	2007-03-12 08:08:18
3D	50798	1	2010-05-12 11:52:43

3. rating

Περιέχει movieIds μαζί με τους χρήστες (userId), τις αξιολογήσεις (rating) που έδωσαν και τα timestamps. Μια ταινία (MovieId)

μπορεί να έχει πολλές αξιολογήσεις (rating) από πολλούς διαφορετικούς χρήστες (userId).

userId	movieId	rating	timestamp
3	1	4	1999-12-11 13:36:47
6	1	5	1997-03-13 17:50:52
8	1	4	1996-06-05 13:37:51

4. link

Το link συνδυάζει τα movieId με τα imdbid και τα tmdbid, άρα συνδέει τα identifiers των ταινιών με τα αντίστοιχα id των εξωτερικών πηγών imdb και tmdb.

movieId	imdbid	tmdbid
1	114709	862
2	113497	8844
3	113228	15602

5. genome_tags

Τα genome_tags περιέχουν την περιγραφή (tag) του κάθε tag (tagId).


tag	tagId
007	1
007 (series)	2
18th century	3

6. genome_scores

Τα genome_scores περιέχουν το relevance του κάθε tag (tagId) με την κάθε ταινία (movieId). Το relevance είναι από 0 μέχρι 1.

movielfd	tagld	relevance
1	1	0.025
1	2	0.025
1	3	0.05775

- Οι σχέσεις μεταξύ των πινάκων φαίνονται στην παρακάτω εικόνα



Cleaning

Πλήθος εγγραφών στο αρχικό dataset:

- movieId: 27.278
- userId: 138.493
- rating: 20.000.263
- tag: 38.642
- genre: 1.342

Πλήθος μοναδικών εγγραφών μετά από Processing:

- movieId: 27.262
- userId: 138.493
- rating: 20.000.263
- tag: 38.642
- genre: 1.342

Στην αρχή για τα αρχεία movie και rating εντοπίσαμε 16 διπλές ταινίες και αφαιρέσαμε την δεύτερη εμφάνιση, ενώνοντας τα genres, αν διέφεραν. Στην συνέχεια, στο rating αντικαταστήσαμε τα διπλότυπα movieId με αυτά που κρατήσαμε στο προηγούμενο βήμα. Ενώσαμε movie και rating, κάνοντας αντιστοίχιση κάθε ταινία με το rating του κάθε χρήστη, έχοντας αποτέλεσμα να μην επιλεχθούν ταινίες που δεν είχαν αντιστοίχιση με κανένα rating. Έτσι, καταλήξαμε να έχουμε καθαρίσει τα δεδομένα και να είναι έτοιμα για feature engineering, όπου χρησιμοποιώντας το καθαρισμένο dataset, βρίσκουμε καινούργιες σχέσεις μεταξύ των δεδομένων.

Feature engineering

Φτιάξαμε ένα python script που υπολογίζει το μέσο rating κάθε ταινίας (avg_movie_rating), πόσα rating είχε κάθε ταινία (rating_count), πόσο κοντά ήταν τα ratings μεταξύ τους (rating_std) και το έτος κυκλοφορίας (release_year), πόσα είδη έχει (genre_count).


	title	genres	movieId	avg_movie_rating	rating_count	rating_std	release_year	genre_count
1	Toy Story (1995)	Adventure Ani...	1	3.92124	49695	0.889012	1995	5
2	Jumanji (1995)	Adventure Chil...	2	3.21198	22243	0.95115	1995	3
3	Grumpier Old ...	Comedy Roma...	3	3.15104	12735	1.00664	1995	2

Παρατηρήσεις

Διερευνητική ανάλυση δεδομένων

Στατιστικά & Visualization

Η παρακάτω εικόνα δείχνει το συνολικό μέσο rating προς τον αριθμό των συνολικών rating.



Παρατηρούμε πως το 61% των ταινιών έχουν μέση αξιολόγηση από 3 μέχρι 4. Επιπλέον υπάρχουν 7% ταινίες που έχουν μέση αξιολόγηση πάνω από 4 σε σχέση με 13% που είναι κάτω από 2.5.