



Πανεπιστήμιο Δυτικής Αττικής
Τμήμα μηχανικών πληροφορικής και υπολογιστών

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Νικολάου Λουκάς (22390158)
Κατεχάκης Γεώργιος (22390087)
Χότζα Σέρτζιο (22390301)
Κωνσταντίνος Γιακουμής (21390035)

[Github Link](#)

Data Set

Χρησιμοποιήσαμε το MovieLens Dataset με 20 data entries. Το dataset χωρίζεται σε 6 αρχεία csv με την στήλη movieId και userId να μοιράζονται μέσα στους πίνακες. Άρα όλα τα αρχεία έχουν ένα id (movieId) ξεκινώντας από το 1 και ανεβαίνουν με μη σταθερό ρυθμό, αρχίζοντας να αυξάνονται κατά 1 και στην συνέχεια αυξάνονται κατά τυχαίο αριθμό.

Στατιστικά:

- movieId: 27.278
- userId: 138.493
- rating: 20.000.263
- tag: 38.642
- genre: 1.342

1. movie

Υπάρχουν τίτλοι (title) ταινιών ξεκινώντας από το 1995 μέχρι το 2015. Το κάθε entry έχει και το είδος ή είδη (genres) όπως Drama, Comedy, etc με κάποιες να έχουν (no genre) για είδος.

2. tag

Περιέχει τα userId των ρηστών που έδωσαν tags στις ταινίες. Τα tag για κάθε movieId και τα timestamps που δείχνει πότε δόθηκε το tag από ένα συγκεκριμένο userId.

3. rating

Περιέχει movieIds μαζί με τους χρήστες (userid), τις αξιολογήσεις (rating) που έδωσαν και τα timestamps. Μια ταινία (MovieId) μπορεί να έχει πολλές αξιολογήσεις (rating) από πολλούς διαφορετικούς χρήστες (userid).

4. link

Το link συνδυάζει τα movieId με τα imdbid και τα tmdbid, άρα συνδέει τα identifiers των ταινιών με τα αντίστοιχα id των εξωτερικών πηγών imdb και tmdb.

5. **genome_tags**

6. **genome_scores**