



Πανεπιστήμιο Δυτικής Αττικής
Τμήμα μηχανικών πληροφορικής και υπολογιστών

Διαχείριση Δεδομένων Μεγάλης Κλίμακας

Νικολάου Λουκάς (22390158)
Κατεχάκης Γεώργιος (22390087)
Χότζα Σέρτζιο (22390301)
Κωνσταντίνος Γιακουμής (21390035)

[Github Link](#)

Περιεχόμενα

Dataset	3
Περιγραφή dataset	3
Περιγραφή εγγραφών του Dataset	6
Διερευνητική ανάλυση δεδομένων	6
Στατιστικά & Visualization	6

Dataset

Περιγραφή dataset

Χρησιμοποιήσαμε το MovieLens Dataset με 20 data entries. Το dataset χωρίζεται σε 6 αρχεία csv με την στήλη movieId και userId να μοιράζονται μέσα στους πίνακες. Τα αρχεία που έχουν ένα movieId ξεκινάνε από το 1 και ανεβαίνουν με μη σταθερό ρυθμό, αρχίζοντας να αυξάνονται κατά 1 και στην συνέχεια αυξάνονται κατά τυχαίο αριθμό.

1. movie

Υπάρχουν τίτλοι (title) ταινιών ξεκινώντας από το 1891 μέχρι το 2015. Το κάθε entry έχει και το είδος ή είδη (genres) όπως Drama, Comedy, etc με 246 να έχουν (no genre) για είδος (genres).

title	genres	movieId
Toy Story (1995)	Adventure Animation Children Comedy Fantasy	1
Jumanji (1995)	Adventure Children Fantasy	2
Grumpier Old Men (1995)	Comedy Romance	3

2. tag

Περιέχει τα userId των ρηστών που έδωσαν tags στις ταινίες. Τα tag για κάθε movieId και τα timestamps που δείχνει πότε δόθηκε το tag από ένα συγκεκριμένο userId.

tag	userId	movieId	timestamp
2009 reissue in Stereoscopic 3-D	123297	1	2011-05-28 19:39:28
3D	29750	1	2007-03-12 08:08:18
3D	50798	1	2010-05-12 11:52:43

3. rating

Περιέχει movieIds μαζί με τους χρήστες (userId), τις αξιολογήσεις (rating) που έδωσαν και τα timestamps. Μια ταινία (MovieId)

μπορεί να έχει πολλές αξιολογήσεις (rating) από πολλούς διαφορετικούς χρήστες (userId).

userId	movieId	rating	timestamp
3	1	4	1999-12-11 13:36:47
6	1	5	1997-03-13 17:50:52
8	1	4	1996-06-05 13:37:51

4. link

Το link συνδυάζει τα movieId με τα imdbid και τα tmdbid, άρα συνδέει τα identifiers των ταινιών με τα αντίστοιχα id των εξωτερικών πηγών imdb και tmdb.

movieId	imdbid	tmdbid
1	114709	862
2	113497	8844
3	113228	15602

5. genome_tags

Τα genome_tags περιέχουν την περιγραφή (tag) του κάθε tag (tagId).


tag	tagId
007	1
007 (series)	2
18th century	3

6. genome_scores

Τα genome_scores περιέχουν το relevance του κάθε tag (tagId) με την κάθε ταινία (movieId). Το relevance είναι από 0 μέχρι 1.

moviId	tagId	relevance
1	1	0.025
1	2	0.025
1	3	0.05775

- Οι σχέσεις μεταξύ των πινάκων φαίνονται στην παρακάτω εικόνα



Περιγραφή εγγραφών του Dataset

Πλήθος εγγραφών στο αρχικό dataset:

- movieId: 27.278
- userId: 138.493
- rating: 20.000.263
- tag: 38.642
- genre: 1.342

Πλήθος μοναδικών εγγραφών μετά από Processing:

- movieId: 27.262
- userId: 138.493
- rating: 20.000.263
- tag: 38.642
- genre: 1.342

Στο processing του movie βγάλαμε τις διπλότυπες εγγραφές κρατώντας μόνο την πρώτη, στην συνέχεια ενημερώσαμε τα rating ώστε τα διπλά movieIds να δείχνουν μόνο στην εγγραφή που κρατήθηκε στο movie.


Κρατήσαμε μόνο τα αρχεία movie και rating, καθώς μόνο αυτά ...

(Insert Thing Here)

Διερευνητική ανάλυση δεδομένων

Στατιστικά & Visualization

Η παρακάτω εικόνα δείχνει το συνολικό μέσο rating προς τον αριθμό των συνολικών rating.



Παρατηρούμε πως το 61% των ταινιών έχουν μέση αξιολόγηση από 3 μέχρι 4. Επιπλέον υπάρχουν 7% ταινίες που έχουν μέση αξιολόγηση πάνω από 4 σε σχέση με 13% που είναι κάτω από 2.5.